INFORME TÉCNICO

Proyecto 3 Estadística del reggaetón

Evolución del contenido temático y del lenguaje sexualmente explícito en canciones de reggaetón de 2010 a 2025

Valentina Cabarcas de la Hoz, Mariana Carrillo Candanoza y Albert Devanis Gastelbondo Suárez

Proyecto 3 · Estadística Industrial

Ingeniería Industrial · Universidad del Magdalena

Docente Enrique J. De La Hoz Domínguez

Semestre 2026 II

Santa Marta, Colombia, octubre de 2026

1 Resumen

Se examinó la variación del lenguaje relacionado con sexualidad y las diferencias temáticas en un corpus de 240 canciones de reggaetón de 2010–2025, con 15 registros por año. Se seleccionaron canciones presentes en tops o entre las más escuchadas, tomando como referencias principales Spotify y Billboard. Se aplicó un diccionario de 1.420 entradas (1.419 formas distintas tras normalización) a 108.400 palabras. El análisis temporal utilizó Spearman, regresión lineal y un modelo cuasibinomial; la comparación entre 140 canciones de hombres y 85 de mujeres empleó Mann–Whitney con ajuste Benjamini–Hochberg.

El indicador combinado de sexualidad y discriminación promedió 0,896 % y aumentó con el año ($\rho = 0{,}3072$; $p < 0{,}001$), con una pendiente de 0,0536 puntos porcentuales anuales e IC 95 % [0,0233; 0,0839]. Tras el ajuste por comparaciones múltiples, identidad urbana y onomatopeyas presentaron diferencias entre hombres y mujeres ($r = 0{,}312$ y 0,229). En las 85 canciones de mujeres se identificaron seis asociaciones temporales con $p < 0{,}05$, sin ajuste por multiplicidad: cinco positivas y una negativa, correspondiente a romance.

Los hallazgos describen coincidencias léxicas en la muestra. Los indicadores no aíslan exclusivamente la sexualidad explícita. Se aplicó una medición automatizada mediante diccionario, sin codificación contextual con Claude ni doble anotación humana; por ello, no se estimó el acuerdo interevaluador ni se atribuye a los conteos una validez semántica demostrada.

Palabras clave: reggaetón, corpus, análisis léxico, género del intérprete, tendencia temporal, diccionario.

2 Introducción y antecedentes

2.1 Preguntas de investigación

Pregunta principal. ¿Varía la proporción de lenguaje sexualmente explícito en los períodos trabajados entre 2010 y 2025?

Primera complementaria. ¿Difiere el contenido temático entre canciones interpretadas por hombres y por mujeres?

Segunda complementaria. ¿Ha cambiado la temática de las canciones de mujeres entre 2010 y 2025?

La canción constituye la unidad de análisis. Se estudia el porcentaje de palabras asociado a categorías del diccionario, su relación con el año registrado y sus diferencias según la etiqueta del intérprete. Las conclusiones se refieren a los textos seleccionados y no a la conducta de los artistas ni a efectos sobre sus audiencias.

2.2 Antecedentes y discusión académica

El análisis de letras permite estudiar cómo se representan el deseo, los vínculos afectivos y las relaciones de género. Su interpretación exige distinguir una referencia sexual de una expresión discriminatoria o de una afirmación de autonomía. Una misma palabra puede adquirir sentidos diferentes según el contexto, por lo que la frecuencia de vocabulario constituye una medida parcial del contenido de una canción.

Una línea de investigación identifica sexualización y objetivación en las representaciones femeninas. Merlyn (2020), al examinar letras y videos de 100 canciones populares de 2018, encontró modelos relacionales tradicionales y negativos. Este antecedente justifica examinar categorías diferenciadas, aunque su análisis audiovisual y su cobertura de un solo año difieren del enfoque textual y longitudinal aplicado al presente corpus.

Otra perspectiva reconoce posibilidades de resignificación. Araüna, Tortajada y Figueras-Maz (2020) estudiaron letras y discursos públicos de Brisa Fenoy, Ms Nina y Tremenda Jauría y describieron el uso del reggaetón para articular mensajes feministas. Sus resultados sitúan la agencia y la disputa por el significado dentro del debate, sin establecer que todas las canciones interpretadas por mujeres expresen una misma posición.

Estas perspectivas impiden interpretar la sexualidad como sinónimo automático de subordinación. La presencia de vocabulario sexual, por sí sola, no determina quién ejerce una acción, si existe consentimiento o si una expresión se formula de manera irónica. El diccionario distingue sexualidad, género y poder, consentimiento y discriminación; los conteos disponibles permiten describir su frecuencia, pero no resolver todas esas relaciones contextuales.

2.3 Objetivos y alcance del análisis

El objetivo general es examinar la evolución del contenido léxico relacionado con sexualidad y las diferencias temáticas según el género del intérprete entre 2010 y 2025. Se busca describir la composición del corpus, cuantificar coincidencias por canción, evaluar su asociación temporal, comparar las distribuciones temáticas entre canciones de hombres y mujeres y estudiar los cambios dentro del conjunto femenino.

Se calcularon porcentajes por canción mediante un diccionario multicategoría. La evolución general se examinó con Spearman, regresión lineal y un modelo cuasibinomial. La comparación temática entre hombres y mujeres utilizó Mann–Whitney y ajuste Benjamini–Hochberg para 21 categorías. El análisis femenino empleó Spearman y regresión lineal por categoría, con valores p individuales. El nivel de referencia fue 0,05.

Se distingue el porcentaje de palabras que coincide con una categoría dentro de una letra de la proporción de canciones que contiene esa categoría. Los indicadores analizados corresponden al primer caso. Por tanto, sus resultados no estiman directamente la prevalencia de canciones sexualmente explícitas ni clasifican el tema global de cada texto.

3 Diseño muestral

3.1 Marco y selección

La población de interés comprende canciones de reggaetón del período 2010–2025. Se seleccionaron canciones presentes en tops o entre las más escuchadas, con base principalmente en Spotify y Billboard. La búsqueda se realizó con apoyo de inteligencia artificial y se organizó con igual número de registros por año. El corpus corresponde a una selección intencional por popularidad con cuotas anuales, no a un sorteo probabilístico.

Se trabajó con 240 canciones con letra y seis campos de origen. La rutina Limpiar_duplicados.R identifica letras exactamente iguales, conserva su primera aparición y excluye las repeticiones posteriores. Los archivos de entrada y salida contienen 240 registros. La comparación textual exacta no detecta por sí misma versiones con diferencias de transcripción ni verifica la correspondencia entre el título y la letra.

Grupo registrado	Canciones	Uso en los análisis
Hombres	140	Comparación temática
Mujeres	85	Comparación y evolución temática
Colaboración mixta	14	Solo análisis principal
Colaboración entre hombres	1	Solo análisis principal
Total	240	Análisis principal

Tabla 1. Composición del corpus según la etiqueta del intérprete. La comparación temática utilizó 225 canciones y excluyó los 15 registros con etiquetas de colaboración.

3.2 Cobertura temporal y comparación

Cada uno de los 16 años contiene 15 canciones. El análisis principal utilizó los 240 registros. Para la comparación temática se seleccionaron exclusivamente las etiquetas «Hombre» y «Mujer», con 140 y 85 canciones, respectivamente; se excluyeron 14 colaboraciones mixtas y una colaboración entre hombres. Los resultados de evolución femenina contienen 85 canciones y cubren los 16 años.

La distribución de 15 canciones por año permite comparar el contenido léxico con igual número total de observaciones en cada año. El criterio de inclusión fue la presencia en tops o entre las canciones más escuchadas, tomando como referencias principales Spotify y Billboard. El año registrado en la base organizó las comparaciones temporales del análisis.

La selección por popularidad delimita la cobertura del corpus a las canciones incorporadas bajo ese criterio. La cuota anual uniforme facilita la comparación temporal, pero no reproduce necesariamente la distribución de toda la producción del género. Las conclusiones se refieren a la muestra estudiada y no se presentan como estimaciones representativas de todo el reggaetón.

4 Fuentes y construcción del corpus

4.1 Fuentes y trazabilidad

El procesamiento analítico se desarrolló en cuatro scripts en R. Limpiar_duplicados.R construye la entrada sin repeticiones textuales exactas; analisis_obscenidad.R obtiene los indicadores generales; Analisis hombres y mujeres.R compara categorías por género; y Analisis mujeres.R estudia su evolución en el conjunto femenino. Se utilizaron dos bases de canciones y el Diccionario Maestro, y se generaron tres libros de resultados, gráficos y resúmenes.

La búsqueda de canciones se realizó con apoyo de inteligencia artificial, tomando como referencias principales los tops y registros de popularidad de Spotify y Billboard. Este uso de IA se registra en la bitácora del proyecto. La base de trabajo conserva año, canción, artista, género del intérprete, URL Genius y letra. Los enlaces de letras permiten identificar las páginas asociadas a los textos utilizados; los datos se organizaron para su procesamiento y comparación por canción.

Archivo o componente	Contenido
canciones_sin_letras_repetidas.xlsx	Metadatos y letras de las canciones
analisis_obscenidad_por_cancion.xlsx	Resumen por canción, resumen global, tendencias y coincidencias
analisis_genero_tematico.xlsx	Comparación estadística y proporciones por canción
analisis_evolucion_mujeres.xlsx	Tendencias por categoría, proporciones y promedios anuales
Diccionario Maestro	Categorías, términos y campos de interpretación

Tabla 2. Insumos y salidas del procesamiento. Las tablas de resultados conservan una observación por canción en sus hojas analíticas; el detalle de coincidencias contiene varias ocurrencias por canción.

4.2 Tratamiento de derechos de autor

Las letras se utilizaron como insumo interno para el análisis, sin reproducir sus textos completos en el informe ni en los archivos publicados. La base divulgada contiene únicamente los títulos de las canciones y los años registrados, con el propósito de identificar el corpus estudiado. El informe presenta conteos, proporciones, resultados estadísticos y gráficos derivados del procesamiento, respetando la restricción de no redistribuir las letras completas.

5 Instrumentos de medición

5.1 Diccionario maestro

El Diccionario Maestro contiene términos y expresiones con categoría principal, subcategoría, explicitud propuesta, polisemia, definición operativa, regla de desambiguación y ejemplo ilustrativo. Sus hojas complementarias incluyen taxonomía, ambigüedades, fuentes, metodología, protocolo y una plantilla de anotación. Se utilizaron las categorías y etiquetas definidas en este recurso como referencia para la medición automatizada. El análisis principal normalizó las 1.420 entradas y conservó 1.419 formas distintas tras eliminar un duplicado generado por la normalización («quieres» y «¿quieres?» coinciden al retirar los signos de puntuación), distribuidas en 21 categorías.

La taxonomía separa sexualidad e intimidad (deseo, prácticas, anatomía y eufemismos) de género y poder (autonomía, control, cosificación y normas) y de consentimiento (aceptación, rechazo y coerción). También diferencia discriminación, violencia, romance y desamor. Incluye dimensiones contextuales como identidad urbana, cultura musical, movilidad y vocalizaciones. Estas definiciones orientan la interpretación; el algoritmo asigna coincidencias por forma y no aplica una decisión contextual a cada ocurrencia.

5.2 Indicadores del análisis principal

Se normalizaron las letras y el diccionario a minúsculas, sin tildes, conservando la ñ. Se retiraron signos, apóstrofes y etiquetas de secciones. La búsqueda priorizó las expresiones más largas y evitó reutilizar posiciones ya cubiertas. Cada expresión aportó tantas palabras como tokens contenía. Se mantuvieron las onomatopeyas y las repeticiones; por ello, los coros repetidos contribuyeron de nuevo al conteo. La proporción se calculó respecto al total de palabras conservadas.

$$P_{\mathrm{i}} = 100 \times C_{\mathrm{i}} / T_{\mathrm{i}}$$

En la ecuación, T_i es el total de palabras de la canción i y C_i el número de posiciones cubiertas por la definición analizada. El indicador denominado «obscenas» en el código combina SEXUALIDAD y DISCRIMINACION, con 204 entradas. Otro indicador reúne todas las coincidencias cuya explicitud se marcó como «Explícito», incluidas referencias sexuales y violentas. Ninguno representa exclusivamente la intersección entre sexualidad y explicitud; esa distinción delimita la respuesta a la pregunta principal.

5.3 Polisemia y sensibilidad

Se calculó una variante del indicador combinado que excluye entradas cuyo campo de polisemia es «Sí». Su media fue 0,74 %, según el resumen de hallazgos. Esta sensibilidad utiliza las etiquetas del diccionario y no equivale a verificar el sentido de cada coincidencia. Las reglas y ejemplos de las hojas complementarias documentan precauciones de interpretación, pero no constituyen resultados de validación sobre las canciones.

5.4 Medición temática y pruebas implementadas

Los análisis temáticos transformaron ñ en n, retiraron una lista de palabras frecuentes y conservaron tokens de más de dos caracteres. Se contó cada palabra individual coincidente con una categoría y se dividió entre el total retenido. Las expresiones de varias palabras no coinciden con un único token bajo este procedimiento. En consecuencia, sus porcentajes tienen un denominador y una cobertura distintos de los utilizados en el análisis principal.

La limpieza retiró etiquetas y residuos de páginas de letras. La expresión «you might also like.*» puede eliminar también el texto posterior a esa marca (R Core Team, s. f.). En el análisis principal se evaluó la asociación con el año mediante Spearman bilateral y se ajustó una regresión lineal de la proporción, con pendiente e IC 95 %. También se estimó un modelo cuasibinomial con enlace logit sobre el conteo de coincidencias y el resto de palabras de cada canción.

La comparación por género utilizó Mann–Whitney bilateral mediante wilcox.test, con exact = FALSE. Se resumieron medias y un efecto r, y se ajustaron los 21 valores p con Benjamini–Hochberg mediante p.adjust. Esta corrección controla la tasa de falsos descubrimientos. La prueba contrasta distribuciones; sin formas distribucionales equivalentes, su resultado no debe interpretarse exclusivamente como diferencia de medianas.

$$r = |Z| / \sqrt{N}$$

El efecto r se obtuvo con Z = qnorm(p/2), a partir del valor p bilateral, y N igual al total de canciones comparadas. En mujeres se calcularon Spearman, pendiente lineal y R^2 para cada categoría, sin ajuste por multiplicidad. El script incorpora extracción de secciones femeninas de colaboraciones; las salidas guardadas contienen 85 canciones y no permiten atribuir los resultados a un conjunto ampliado. No se realizaron diagnósticos de residuos ni verificaciones formales de supuestos en los scripts analizados.

5.5 Alcance contextual del conteo léxico

La medición implementada utiliza coincidencias de palabras y expresiones con el diccionario. No se utilizó Claude para asignar categorías contextuales a las canciones. Las definiciones, reglas y ejemplos del Diccionario Maestro orientaron la interpretación de los indicadores, sin constituir una codificación contextual del corpus mediante un modelo de lenguaje.

La frecuencia de una categoría indica presencia de su vocabulario bajo las reglas de búsqueda. No demuestra aprobación del contenido ni identifica automáticamente ironía, negación, narrador o intención. La interpretación contextual y su validación se mantienen diferenciadas de los conteos efectivamente calculados.

6 Alcance y limitaciones del instrumento

6.1 Medición léxica automatizada

Se utilizó un procedimiento automatizado de análisis léxico para cuantificar la proporción de palabras y expresiones asociadas a las categorías del diccionario. La medición se basó en identificar coincidencias entre el vocabulario de las letras y las entradas previamente clasificadas, y calcular sus frecuencias relativas por canción. No se realizó una clasificación temática manual de las canciones ni una codificación contextual mediante Claude.

La elección de este procedimiento respondió al interés de estudiar las proporciones léxicas mediante reglas uniformes de búsqueda y conteo. Así, se redujo la dependencia de valoraciones individuales al procesar cada canción. Sin embargo, la aplicación de un diccionario no elimina los posibles sesgos de sus categorías ni garantiza que todas las coincidencias conserven el significado previsto dentro de las letras.

No se efectuó una doble anotación humana ni una comparación entre clasificaciones humanas y respuestas de un modelo de lenguaje; por tanto, no se calcularon coeficientes kappa ni matrices de confusión. Los resultados describen la presencia y frecuencia del vocabulario definido por el diccionario y las asociaciones estadísticas obtenidas a partir de esos conteos. Su interpretación considera las limitaciones relacionadas con la polisemia, el doble sentido, la negación y el contexto, sin atribuirles el alcance de una clasificación semántica validada.

7 Resultados

7.1 Distribución de los indicadores léxicos

El análisis principal incluyó 240 canciones y 108.400 palabras. La proporción combinada de sexualidad y discriminación tuvo una media de 0,896 %, mediana de 0,513 % y rango de 0 a 5,414 %. Se registraron 59 canciones sin coincidencias (24,6 %) y 27 con al menos 2 % (11,2 %, según el redondeo de la salida). La concentración en valores bajos y la presencia de algunas observaciones elevadas explican que la media supere la mediana.

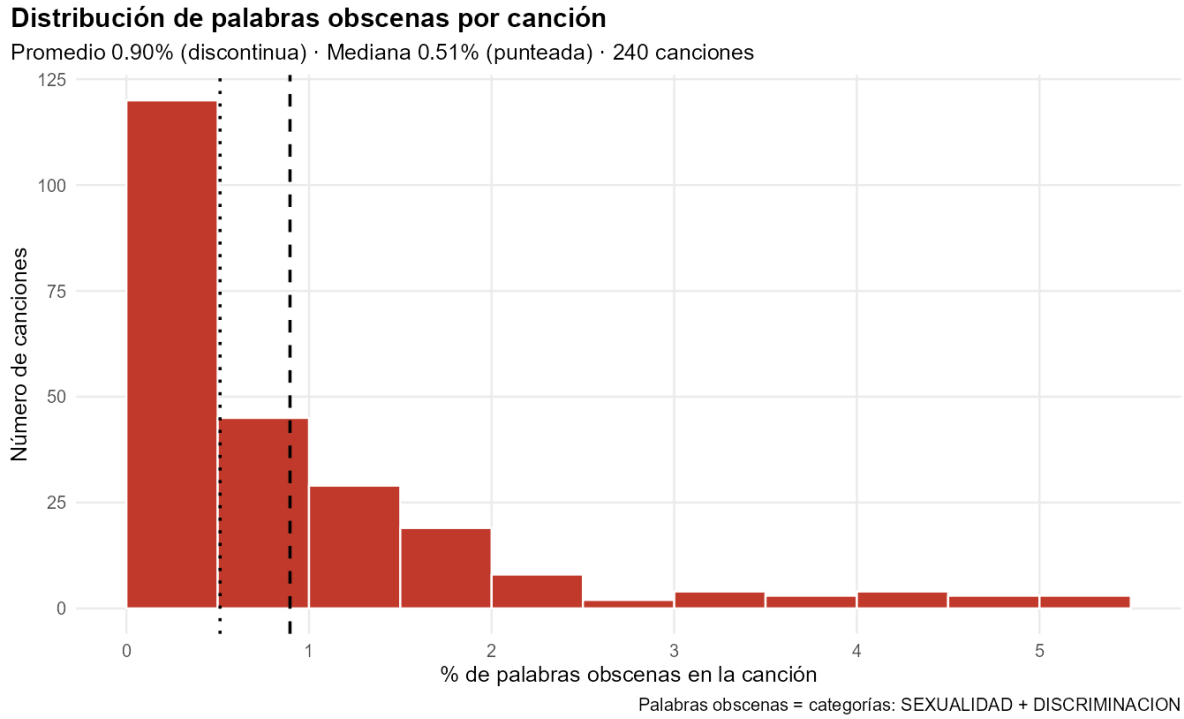


Figura 1. Distribución del indicador combinado de sexualidad y discriminación en 240 canciones de 2010–2025. Las líneas discontinua y punteada indican media y mediana. El denominador corresponde a las palabras tras la limpieza principal. Fuente: grafico_histograma.png y resumen_por_cancion.

Indicador	Resultado	Salida
Proporción combinada media	0,896 %	resumen_global
Proporción combinada mediana	0,513 %	resumen_global
Proporción combinada mínima y máxima	0,000 % y 5,414 %	resumen_global
Proporción media de términos explícitos	0,342 %	resumen_global
Media combinada sin polisemia marcada «Sí»	0,74 %	resumen_hallazgos.txt

Tabla 3. Estadísticos del análisis principal. Fuente: resumen_global de analisis_obscenidad_por_cancion.xlsx y resumen_hallazgos.txt. Los promedios asignan el mismo peso a cada canción.

7.2 Variación temporal y pregunta principal

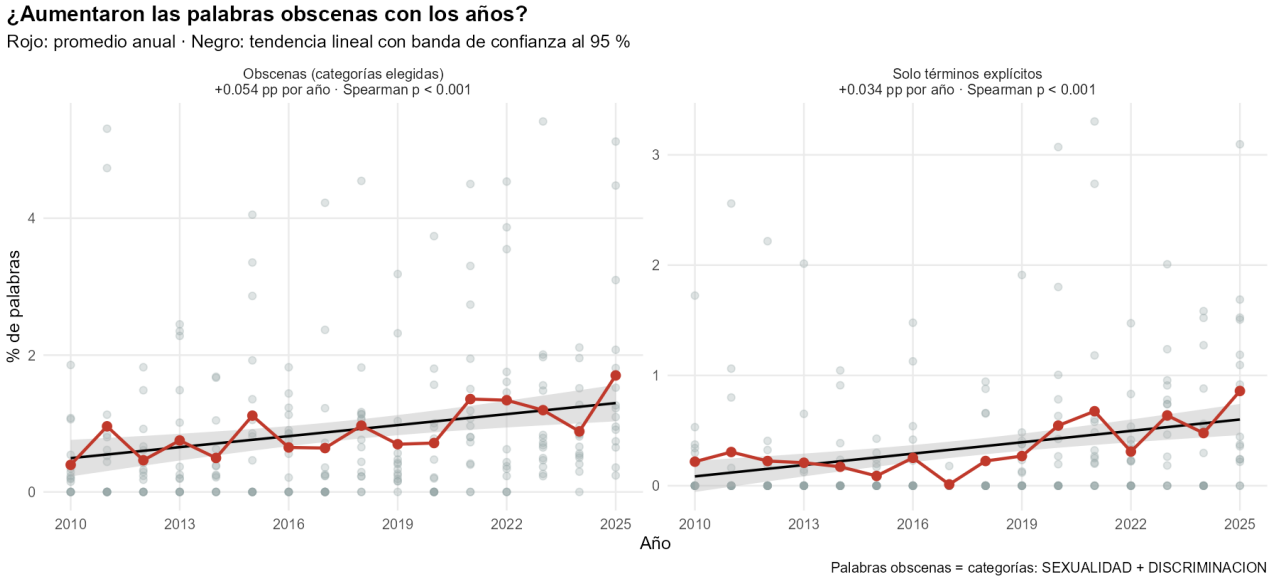


Figura 2. Tendencias del indicador combinado y de los términos explícitos generales en 240 canciones de 2010–2025. Los puntos representan canciones, la línea roja indica medias anuales y la negra el ajuste lineal con IC 95 %. Las escalas verticales difieren entre paneles. Fuente: grafico_tendencia.png. «Explícitos» incluye referencias de distintas categorías.

Medida	ρ de Spearman	Cambio anual en pp e IC 95 %	R^2
Sexualidad y discriminación	0,3072	0,0536 [0,0233; 0,0839]	0,0486
Términos explícitos generales	0,3508	0,0344 [0,0183; 0,0504]	0,0698

Tabla 4. Tendencias registradas en tests_tendencia. pp: puntos porcentuales; ρ: correlación de Spearman. Los intervalos corresponden a pendientes lineales. En ambos indicadores, Spearman presentó p < 0,001; los ceros exportados por redondeo no se interpretan como probabilidades nulas.

La media anual del indicador combinado fue 0,396 % en 2010 y 1,703 % en 2025, con fluctuaciones durante el período. Se observó asociación positiva con el año ($\rho = 0{,}3072$; $p < 0{,}001$). La pendiente lineal fue 0,0536 puntos porcentuales anuales, con IC 95 % [0,0233; 0,0839] y $p = 0{,}0006$. El valor $R^2 = 0{,}0486$ indica que el año explica una fracción reducida de la variación lineal entre canciones.

Los términos explícitos generales también se asociaron positivamente con el año ($\rho = 0{,}3508$; $p < 0{,}001$). La pendiente fue 0,0344 puntos porcentuales anuales, con IC 95 % [0,0183; 0,0504] y $R^2 = 0{,}0698$. La dirección de ambas tendencias coincide, aunque sus definiciones difieren. Estos resultados responden parcialmente a la pregunta principal, pues no aíslan exclusivamente las referencias sexuales explícitas.

El modelo cuasibinomial produjo cambios anuales de 5,9070 % en las odds del indicador combinado y 10,6041 % en las de términos explícitos, con $p = 0{,}0013$ y $p = 0{,}0001$, respectivamente. La transformación $100 \times [\exp(\beta) - 1]$ utilizada en el script expresa un cambio en odds bajo el enlace logit; no representa un incremento relativo directo de la proporción.

7.3 Diferencias temáticas entre hombres y mujeres

Se compararon 140 canciones de hombres y 85 de mujeres en 21 categorías. Cinco presentaron p < 0,05 en las pruebas individuales. Después del ajuste Benjamini–Hochberg, dos conservaron valores inferiores a 0,05: identidad urbana y onomatopeyas. Movilidad, cultura musical y drogas no mantuvieron ese criterio tras el ajuste. La tabla 5 presenta ambos valores p para distinguir estos resultados.

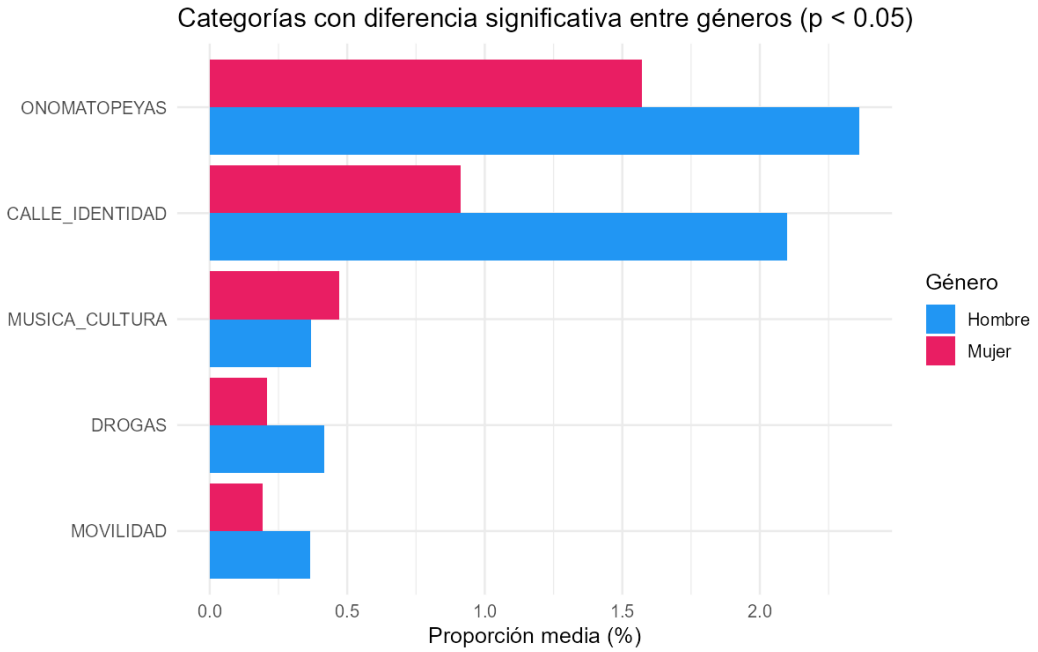


Figura 3. Medias temáticas de las cinco categorías con p < 0,05 sin ajuste, para hombres (n = 140) y mujeres (n = 85). Porcentajes sobre palabras retenidas. Solo identidad urbana y onomatopeyas mantienen p BH < 0,05 en la tabla 5. Fuente: genero_categorias_significativas.png.

Categoría	Media H %	Media M %	p	p BH	r
Identidad urbana	2,0997	0,9123	< 0,001	< 0,001	0,312
Onomatopeyas	2,3623	1,5719	< 0,001	0,006	0,229
Movilidad	0,3642	0,1936	0,01	0,069	0,172
Cultura musical	0,3693	0,4717	0,039	0,185	0,138
Drogas	0,4179	0,2089	0,044	0,185	0,134
Sexualidad	1,0252	1,1163	0,336	0,534	0,064

Tabla 5. Comparación por género. Medias expresadas en porcentajes; r: efecto calculado en el script. Se incluyen cinco diferencias iniciales y sexualidad como referencia. p BH corresponde al ajuste de las 21 pruebas, no solo de las filas mostradas. Fuente: comparacion_estadistica.

Identidad urbana presentó la mayor diferencia de medias entre grupos y r = 0,312; en onomatopeyas, r = 0,229. Ambas medias fueron superiores en hombres. Sexualidad registró 1,0252 % en hombres y 1,1163 % en mujeres, sin diferencia detectable (p BH = 0,534; r = 0,064). Este resultado no demuestra equivalencia.

7.4 Evolución temática de las canciones de mujeres

En 85 canciones de mujeres, seis categorías se asociaron con el año ($p < 0,05$): cinco de forma positiva y romance de forma negativa. El análisis femenino no aplica Benjamini–Hochberg; sus valores p se interpretan sin corrección por multiplicidad.

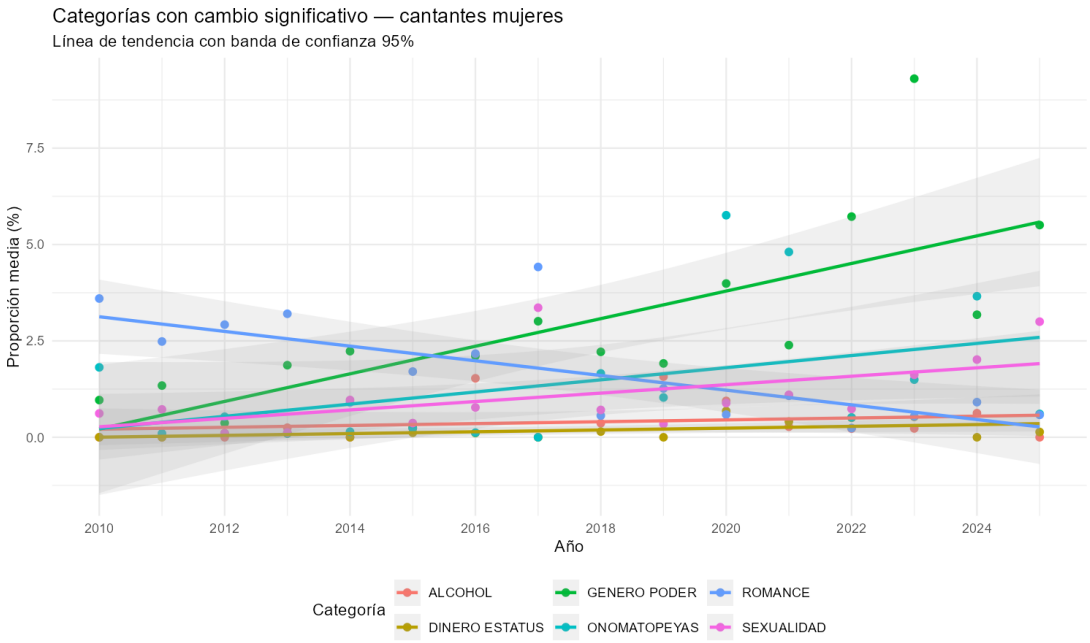


Figura 4. Seis tendencias femeninas con p < 0,05 sin ajuste, 2010–2025 (n = 85). El gráfico ajusta rectas y bandas sobre medias anuales; la tabla 6 utiliza canciones individuales. Porcentajes sobre palabras retenidas. Fuente: mujeres_tendencias_significativas.png.

Género y poder presentó la asociación positiva de mayor magnitud ($\rho = 0,559$), seguida de sexualidad ($\rho = 0,343$). Romance mostró una asociación negativa ($\rho = -0,316$). Sus pendientes fueron +0,3724, +0,1049 y −0,1961 puntos porcentuales anuales. Género y poder incluye autonomía, control y cosificación; su aumento no identifica cuál de esas dimensiones cambió.

Categoría	ρ	p	Cambio anual en pp	R^2
Género y poder	0,559	< 0,001	0,3724	0,272
Sexualidad	0,343	0,001	0,1049	0,070
Romance	-0,316	0,003	-0,1961	0,103
Alcohol	0,256	0,018	0,0239	0,010
Onomatopeyas	0,254	0,019	0,1558	0,047
Dinero y estatus	0,237	0,029	0,0260	0,048

Tabla 6. Tendencias femeninas con p < 0,05 sin ajuste. Cambio anual: pendiente lineal en puntos porcentuales por año; R^2: ajuste lineal sobre canciones. Los valores p corresponden a Spearman. Fuente: tendencias_por_categoria de analisis_evolucion_mujeres.xlsx.

Alcohol, onomatopeyas y dinero y estatus completaron las asociaciones positivas. Los diagramas de caja de 2010–2017 y 2018–2025 son descriptivos; no se realizó una prueba inferencial adicional entre esos períodos.

8 Discusión y limitaciones

8.1 Interpretación de los resultados

Los indicadores combinado y general de términos explícitos aumentaron con el año, pero sus R^2 fueron bajos y persistió una amplia variación entre canciones. El resultado describe una asociación dentro del corpus; no implica un incremento uniforme en cada año o canción. Como las definiciones incluyen categorías distintas, la evidencia no permite concluir de manera exclusiva que aumentó la sexualidad explícita.

La comparación entre hombres y mujeres mostró diferencias en identidad urbana y onomatopeyas tras el ajuste BH. En mujeres, las seis asociaciones temporales se obtuvieron sin corrección. Ambas comparaciones responden preguntas diferentes: una tendencia dentro del conjunto femenino puede coexistir con una diferencia global no detectable en sexualidad entre los dos grupos. Tampoco permite atribuir el cambio a la incorporación de mujeres al género.

8.2 Medición y limpieza

Los resultados no resuelven el contraste entre las interpretaciones de Merlyn (2020) y Araüna et al. (2020). Un aumento de vocabulario sexual puede aparecer en narrativas de subordinación o de agencia. La categoría género y poder reúne sentidos diferentes, por lo que su crecimiento no demuestra mayor empoderamiento. La medición adoptó las categorías del diccionario mediante coincidencias léxicas; la interpretación de estos conteos considera la polisemia y las diferencias de significado según el contexto.

Las reglas de limpieza y conteo difieren entre los análisis. El procedimiento principal reconoce expresiones largas; el temático solo palabras individuales y utiliza otro denominador. La eliminación de residuos de páginas puede retirar contenido de las letras. Las repeticiones también influyen en las tasas. Estas decisiones restringen la comparación directa de porcentajes y la interpretación semántica de sus diferencias.

8.3 Diseño e incertidumbre

La selección por popularidad, la ausencia de probabilidades de inclusión y la distribución desigual de intérpretes limitan la generalización. Varias canciones comparten artistas, lo que puede afectar la independencia asumida. No se controlaron país, popularidad o concentración por intérprete. El código no aporta verificaciones formales de supuestos de las regresiones. La ausencia de significancia tampoco demuestra igualdad entre grupos.

El ajuste BH se aplicó a las 21 comparaciones por género; las 21 tendencias femeninas conservaron valores p individuales. Por ello, no se atribuye el mismo control de falsos descubrimientos a ambos análisis. La selección por popularidad y cuotas anuales delimita la generalización de los resultados.

8.4 Alcance de las conclusiones

El corpus muestra una asociación temporal positiva en los indicadores léxicos generales, dos diferencias temáticas por género tras BH y seis tendencias femeninas sin ajuste. Las conclusiones se limitan a esas medidas y a esta selección de canciones. La respuesta sobre sexualidad explícita es parcial porque los indicadores combinan dimensiones distintas y no resuelven su contexto. La información divulgada excluye letras completas, como se describe en la sección 4.2. Los hallazgos describen variaciones del vocabulario definido por el diccionario y no permiten atribuir efectos a los intérpretes o a sus audiencias.

9 Uso de IA como asistente

Se utilizaron Claude, ChatGPT y Gemini como herramientas de apoyo durante el desarrollo del proyecto. Su participación comprendió la formulación metodológica, la búsqueda y ampliación del corpus, la localización de enlaces de letras, la construcción del Diccionario Maestro, la elaboración y corrección de scripts en R y la revisión de la redacción del informe.

Las propuestas de canciones y enlaces se revisaron para identificar errores de título, artista, año o correspondencia con el género musical. Durante este proceso se detectaron respuestas incorrectas que requirieron rectificaciones. Las decisiones sobre la selección del corpus, las categorías analizadas y los criterios de procesamiento se adoptaron mediante la revisión de las propuestas y de los resultados obtenidos.

El uso de IA como asistente se distinguió de la medición aplicada al corpus. Los indicadores analizados se calcularon mediante coincidencias léxicas con el diccionario y procedimientos programados en R. La asistencia en investigación, programación y escritura no se presentó como una validación contextual del instrumento.

Referencias

Araüna, N., Tortajada, I., & Figueras-Maz, M. (2020). Feminist reggaeton in Spain: Young women subverting machismo through 'perreo'. Young, 28(1), 32–49. https://doi.org/10.1177/1103308819831473

De La Hoz Domínguez, E. J. (2026). Estadística del reggaetón. Proyecto 3. Análisis estadístico de un corpus de letras con validación de un LLM como instrumento de medición [Guía de curso, semestre 2026-II]. Universidad del Magdalena.

Merlyn, M.-F. (2020). Dime lo que escuchas y te diré quién eres. Representaciones de la mujer en las 100 canciones de reggaetón más populares en 2018. Feminismo/s, 35, 291–320. https://doi.org/10.14198/fem.2020.35.11

R Core Team. (s. f.). Regular expressions as used in R [Documentación de R]. https://stat.ethz.ch/R-manual/R-devel/library/base/html/regex.html

Fuentes del corpus. Spotify y Billboard constituyeron las referencias principales para buscar canciones presentes en tops o entre las más escuchadas. La búsqueda asistida por IA se registra en la bitácora del proyecto. La base conserva los enlaces de letras en el campo URL Genius y las tablas y figuras identifican sus salidas de origen. Las referencias académicas y la documentación de R se verificaron el 25 de octubre de 2026.

Anexo A: Bitácora de uso de IA

https://github.com/marianaccza/DATA-FLOW/blob/main/BIT%C3%81CORA%20USO%20DE%20IA.html